

Tehnici de verificare a autenticității imaginilor - ELA (Error Level Analysis)

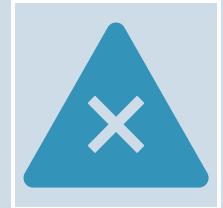
STUDENT: STANCOVICI MARIAN



Context si motivatie



Problema: Trăim în era "Fake News" și a manipulării digitale. Software-urile de editare (Photoshop) și AI-ul fac falsificarea accesibilă oricui.



Nevoia: "A vedea nu mai înseamnă a crede". Este critic să avem instrumente criminalistice automate pentru validarea probelor vizuale.



Soluția propusă: O abordare duală – înțelegerea mecanismului de falsificare și dezvoltarea unui software de detecție bazat pe algoritmul ELA.

Obiectivele proiectului

1. este eficientă (ex: fundaluri uniforme **Valorificarea Metodei ELA prin Analiză Experimentală**: Investigarea impactului **condițiilor de fotografiere** (tipul de iluminare, textura fundalului, zgomotul ISO) asupra acurateței ELA și căutarea scenariilor optime în care ELA vs. texturate).
2. **Dezvoltarea aplicației "Forensic ELA Expert"**: Un laborator virtual complet (Python) pentru analiză și generare de falsuri. (+integrare AI pentru decuparea obiectelor)
3. **Studiul Compresiei JPEG**: Implementarea compresiei locale (zonale) și succesive pentru a testa limitele detecției.
4. **Validare**: Compararea rezultatelor proprii cu standardele industriei (FotoForensics, 29a.ch)

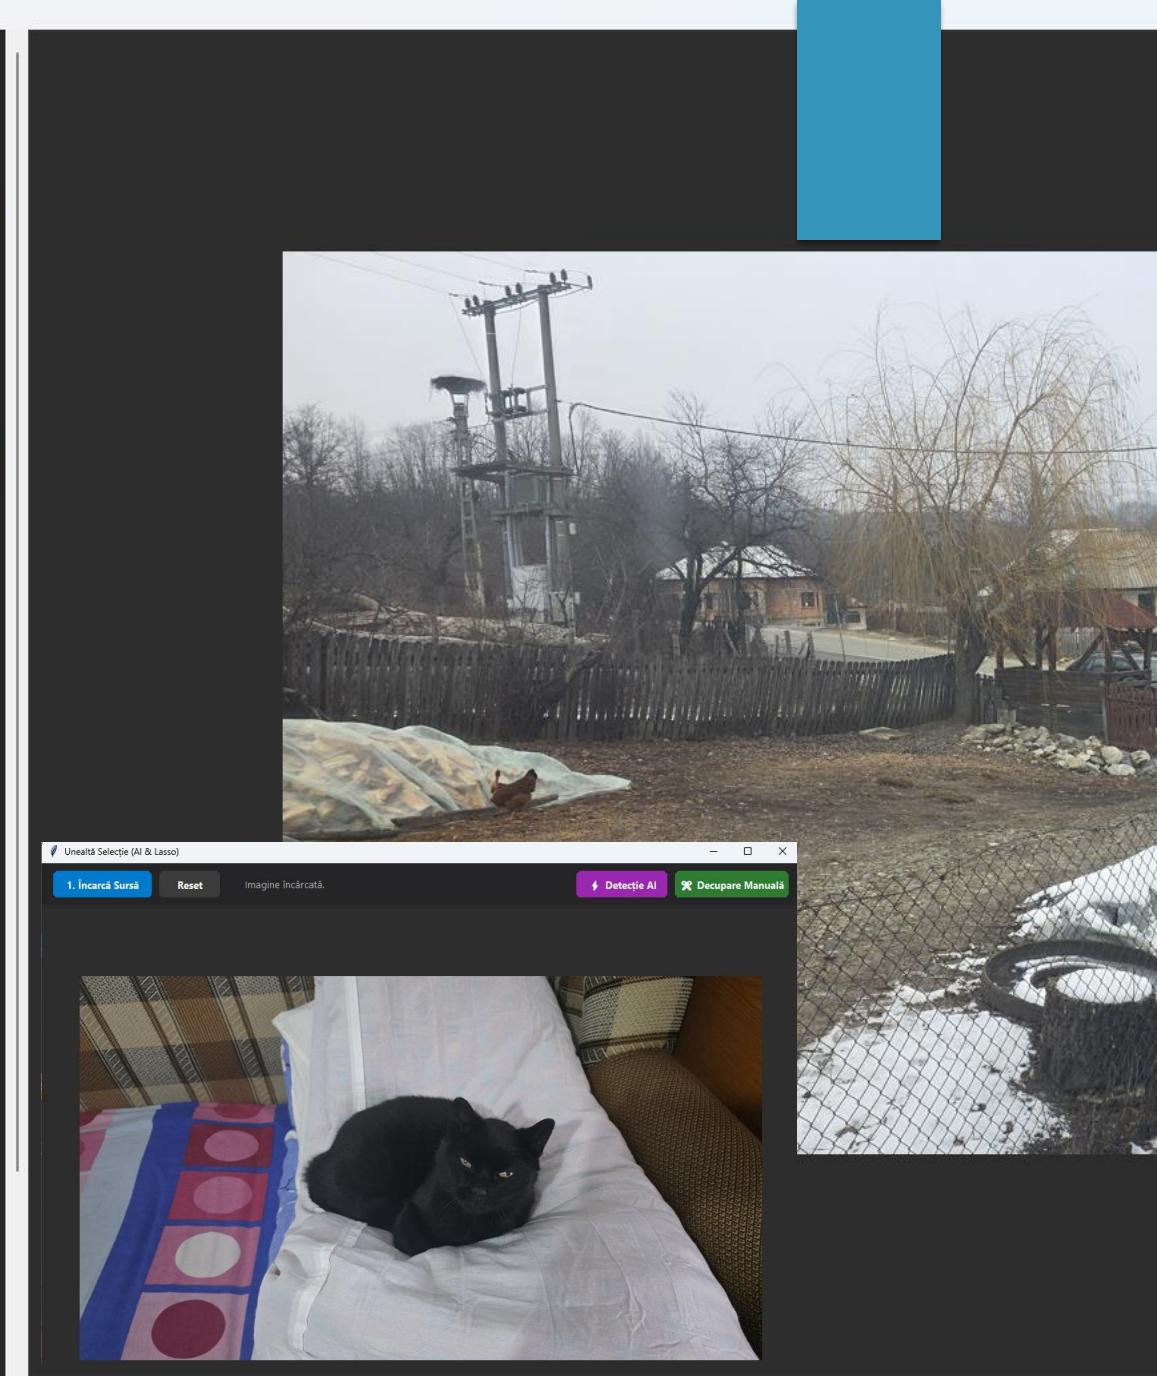
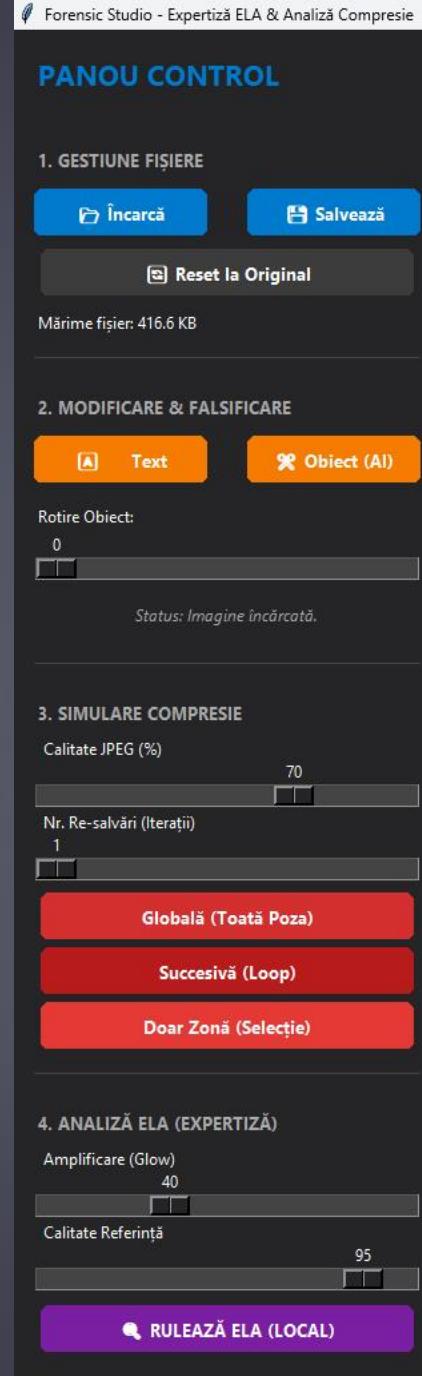
Fundamente Teoretice - Cum funcționează ELA?

- ▶ Compresia JPEG: Este "lossy" (cu pierderi). Imaginea este împărțită în blocuri de 8x8 pixeli.
- ▶ Ipoteza ELA:
 - ▶ O imagine originală are un nivel de eroare uniform.
 - ▶ O imagine modificată (resalvată) introduce discrepanțe. Zonele modificate recent nu au același istoric de compresie ca fundalul.
- ▶ Vizualizare: Algoritmul calculează diferența dintre imaginea originală și o copie recomprimată (la 95%), amplificând rezultatul.
 - ▶ Zone întunecate = Nemodificat.
 - ▶ Zone strălucitoare = Suspect/Modificat.

Arhitectura Aplicației (Contribuția Personală)



- ▶ Limbaj: Python 3.10 + Tkinter (GUI Modern/Dark Mode).+1
- ▶ Biblioteci Cheie:
 - ▶ Pillow: Procesare pixeli și compresie JPEG.
 - ▶ Rembg (U2-Net): Decupare intelligentă a fundalului.
 - ▶ IO/OS: Manipulare buffer în memorie RAM (fără fișiere temporare pe disc).
- ▶ Funcții Unice:
 - ▶ Compresii globale, locale, successive
 - ▶ Analiza ELA + comparatie cu site-uri din industrie
 - ▶ Inserare text/obiecte in imagine





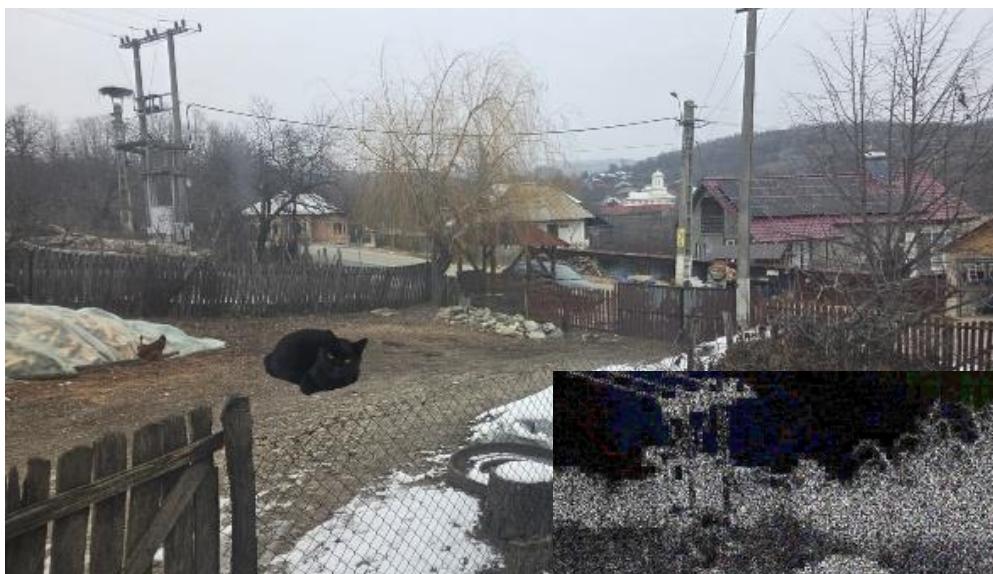
Metodologia Experimentală – Alegerea Imagineilor

- ▶ Pentru validare, am selectat imagini cu caracteristici opuse, pentru a testa sensibilitatea algoritmului la condițiile de captură:
- ▶ **Condiții de Iluminare:** Lumină naturală difuză (Exterior) vs. Lumină artificială direcțională (Interior).
- ▶ **Analiza Frecvențelor:**
 - ▶ **Fundaluri Zgomotoase (High Frequency):** Iarbă, pietriș, garduri (greu de comprimat).
 - ▶ **Fundaluri Uniforme (Low Frequency):** Cer, pereti, gradiențe (ușor de comprimat).

Studiu de Caz 1 - Detectia Insertiilor Insertie pe Fundal Complex ("Curtea")

► Condițiile de Captură:

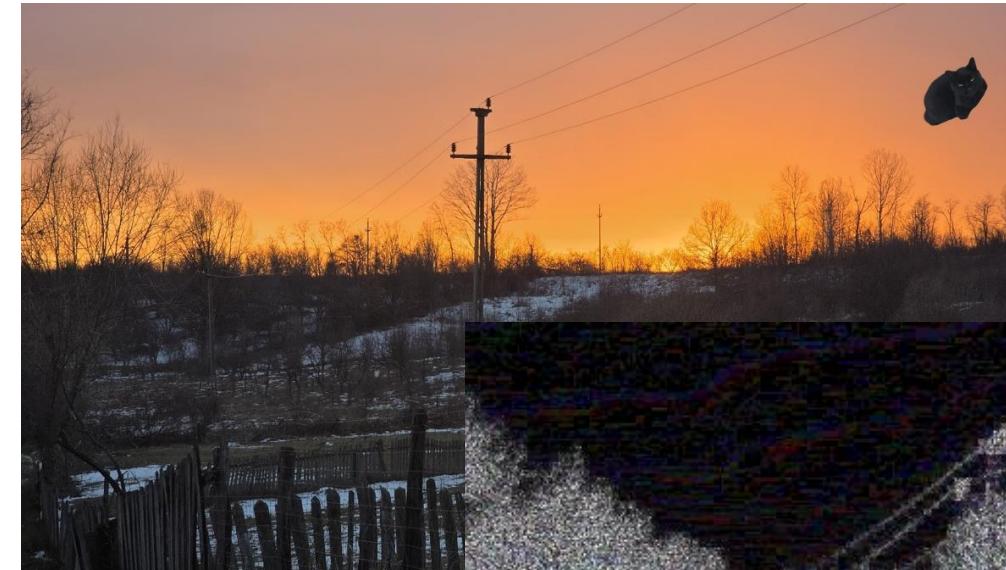
- Fundal: Exterior, zi înnorată. Lumină difuză. Element critic: Pietrișul și Gardul (texturi complexe care generează natural erori ELA mari).
 - Obiect (Pisica): Interior, lumină artificială, Blană Neagră (textură uniformă, contrast mic).
- Analiza Elementelor ELA:
- Observație: Deși fundalul este "zgomotos" (multe puncte albe din cauza pietrișului), pisica iese în evidență printr-o densitate diferită a erorii.
 - Elementul Cheie: Marginile obiectului. Deoarece pisica a fost decupată și lipită, blocurile de 8x8 pixeli de la graniță nu se aliniază cu grila fundalului. ELA evidențiază o "coroană" luminoasă în jurul pisicii, trădând inserția.





Studiu de Caz 2 - Detectia Insertiilor pe Fundal Uniform ("Apusul")

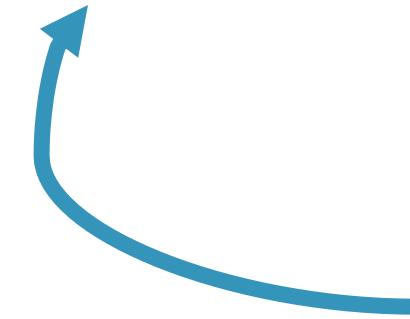
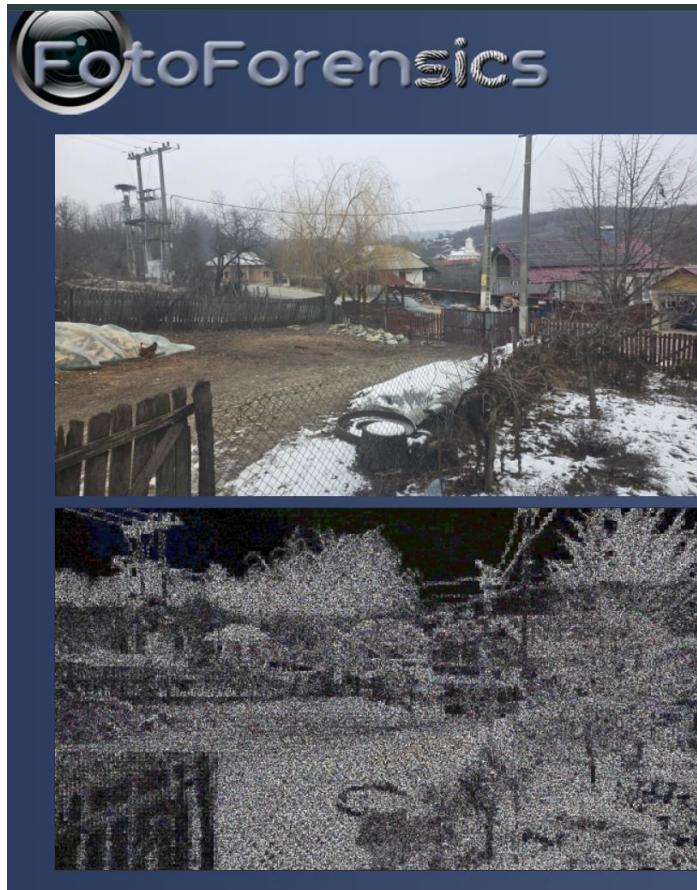
- ▶ Condițiile de Captură:
 - ▶ Fundal: Apus de soare.
 - ▶ Element critic: Gradientul Cerului (tranzitie lină de culoare).
 - ▶ Obiect: Aceeași pisică de interior.
- ▶ Analiza Elementelor ELA:
 - ▶ De ce este detectabil? Cerul, având frecvență joasă, se comprimă extrem de eficient. În ELA, cerul apare complet negru (eroare zero).
 - ▶ Contrastul: Pisica, având o structură de pixeli necompatibilă anterior împreună cu cerul, apare strălucitoare.
 - ▶ Concluzie: ELA este mult mai eficientă pe fundaluri uniforme (cer, apă) decât pe fundaluri texturate.





Studiu de Caz 3 – Compresia Locală (Detectia Retusărilor)

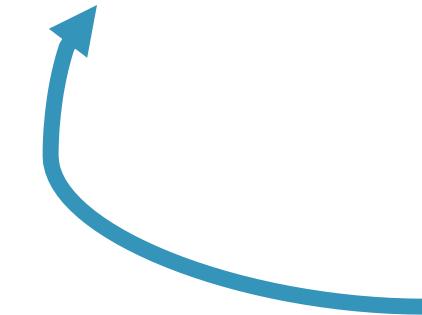
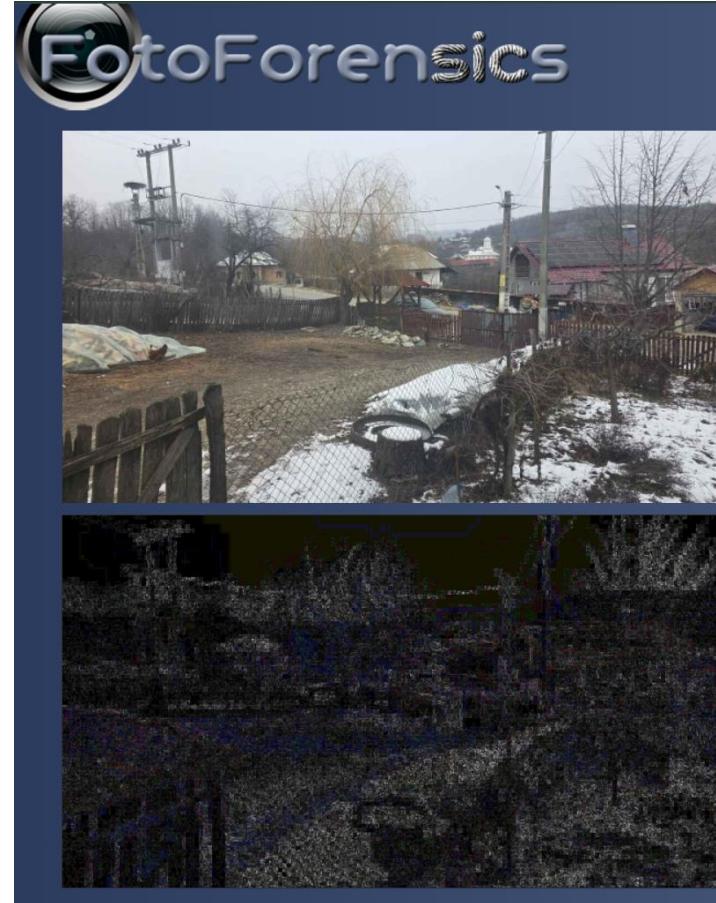
- ▶ Scenariul: Simularea falsificării prin alterarea calității (Q=40%) doar într-o zonă rectangulară centrală, restul imaginii rămânând la calitate înaltă (Q=95%).
- ▶ Analiza Elementelor Vizuale:
 - ▶ Elementele din zonă: Zona selectată cuprinde gardul de lemn (uluci) și o porțiune de pământ situată imediat deasupra acestuia.
 - ▶ Textura: Atât lemnul (cu fibrele și spațiile dintre uluci), cât și pământul sunt texturi neregulate, bogate în detaliu ("high frequency").
 - ▶ Efectul Compresiei: La Q=40%, textura rugoasă a pământului devine "ștearsă", iar muchiile lemnului își pierd claritatea, comparativ cu zona de sârmă din dreapta care a rămas nealterată.
- ▶ Rezultat ELA:
 - ▶ ELA compară nivelul de eroare al zonei centrale cu restul imaginii.
 - ▶ Deoarece detaliile fine ale pământului și lemnului au fost "netezite" de compresia locală, ele generează o eroare matematică diferită față de restul curții.
 - ▶ Concluzie: Zona apare în harta ELA ca un dreptunghi cu o textură distinctă, trădând manipularea.





Studiu de caz 4- Limitele Metodei (Compresia Succesivă)

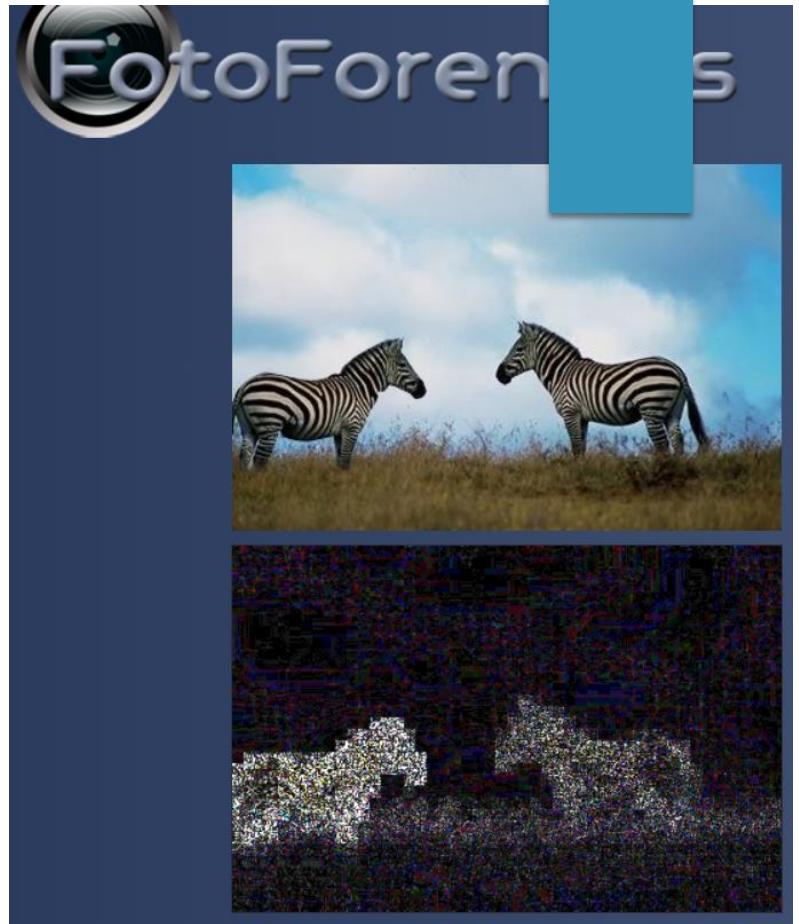
- ▶ Scenariu: Simularea unei imagini virale (resalvată de 10 ori consecutiv la Q=40).
- ▶ Rezultat:
 - ▶ Calitate vizuală: Puternic degradată (pierdere detaliilor, halouri de culoare).
 - ▶ Rezultat ELA: Negru (eroare minimă).
- ▶ Explicație: Imaginea a ajuns la un "minim local" al erorii. Pixelii s-au stabilizat în grila de cuantizare. Aceasta este o metodă de Anti-Forensics.



Validare Încrucișată



- ▶ Rezultatele obținute cu "Forensic ELA Expert" au fost comparate cu platformele consacrate:
 - ▶ FotoForensics.com
 - ▶ Forensically (29a.ch)
- ▶ Concluzie: Algoritmul implementat local oferă rezultate consistente cu standardele industriei.



Concluzii

- ▶ Proiectul a reușit crearea unui instrument hibrid: Laborator de Falsificare + Instrument de Detecție.
- ▶ ELA este un instrument de triere (screening): Indică unde să te uiți, dar nu este o probă absolută (poate genera pozitive false pe texturi complexe).
- ▶ Direcții viitoare: Analiza zgomotului senzorului (Noise Analysis) și utilizarea Deep Learning (CNN) pentru clasificarea automată a hărților ELA.

Multumesc! ☺